

דוח מנהלים: פרויקט זיהוי רחפנים באמצעות למידה עמוקה

מבוא

הגדרת הבעיה- כיום, זיהוי איומים אוויריים, כגון רחפנים, מהווה אתגר משמעותי בתחום הביטחוני. קושי זה נובע מכמה גורמים, ביניהם:

- דמיון חזותי: לעיתים קרובות, רחפנים דומים בצורתם לציפורים או למסוקים קטנים, מה שמקשה על זיהוי מהיר ומדויק.
- תנאי סביבה משתנים: תנאי תאורה, מזג אוויר ותנועה דינמית מקשים אף יותר על תהליך הזיהוי.
- צורך בזיהוי מהיר: בזמן אמת, ישנה דרישה קריטית לקבל החלטות מהירות על בסיס המידע המתקבל ממערכות זיהוי.

מטרת הפרויקט- מטרת הפרויקט היא לפתח מערכת חכמה ויעילה המסוגלת להתמודד עם האתגרים הללו. המערכת תתבסס על טכנולוגיות מתקדמות של למידה עמוקה, ותאפשר:

- זיהוי מדויק: המערכת תוכל להבחין בצורה אמינה בין רחפנים, ציפורים ומסוקים, גם בתנאי תצפית מאתגרים.
- סיווג אוטומטי: המערכת תסווג את האובייקטים שזוהו לקטגוריות הרלוונטיות.
- תמיכה בקבלת החלטות: המידע המתקבל מהמערכת יסייע למקבלי ההחלטות לנקוט בפעולות מתאימות, במידת הצורך.

במילים אחרות, המערכת שיפותח תהווה כלי אסטרטגי בתחום הביטחוני, ותסייע בשמירה על ביטחון האזרחים והמדינה.

תהליך הפיתוח כולל ארבעה שלבים עיקריים-

- הכנת התמונות: בשלב הראשון, התמונות עוברות עיבוד מקדים כדי להכין אותן לתהליך הלמידה.
- אימון המודל: לאחר הכנת התמונות, המערכת עוברת תהליך אימון שבו היא לומדת להבדיל בין סוגי האובייקטים השונים.
- הערכת המודל: בשלב האחרון, בודקים עד כמה המערכת מצליחה לזהות נכון את האובייקטים.
- השוואה בין המודלים השונים.

מאגר הנתונים- מאגר תמונות המכיל 1386 תמונות מ-3 קטגוריות רחפנים (445), ציפורים (478) ומסוקים (463). מקור הנתונים- Kaggel ו-google photos.

תיאוריה

למידה עמוקה, ובפרט רשתות נוירונים קונבולוציוניות (CNN), מאפשרת סיווג תמונות על פי מאפיינים ויזואליים מורכבים. רשתות אלה מסוגלות לזהות תבניות חזותיות בתמונות, מה שהופך אותן לאידיאליות למשימות סיווג של אובייקטים. עם זאת, ישנן מגבלות כמו הצורך בסט נתונים גדול ומגוון, והשפעת תנאי תאורה וזוויות צילום לא רגילות על דיוק המודל.

שיטות למידה ומודלים

במהלך הפרויקט נבדקו מספר מודלים. להלן תיאור כל מודל, הסיבות לבחירה, הפונקציות בהן השתמשנו והתוצאות שהושגו:

CIFAR-10 Model

תיאור: מודל המבוסס על מאגר נתונים CIFAR-10 הכולל 60,000 תמונות צבעוניות מ-10 קטגוריות שונות. **למה:** המודל נבחר בשל התאמתו לסיווג תמונות קטנות וצבעוניות דומות לציפורים ומטוסים. הוא מאפשר שימוש בלמידה מואצת (transfer learning) לשיפור הביצועים במאגר הנתונים שלנו. **Loss Function:** השתמשנו ב-Categorical Crossentropy כיוון שהיא הפונקציה הנפוצה ביותר לסיווג רב-קטגוריות.

Optimizer: Adam, מציע ביצועים טובים על ידי התאמה דינמית של קצב הלמידה.

תוצאות: דיוק של 0.69, המודל התקשה להבחין בין רחפנים למסוקים.

CNN Model

תיאור: מודל עם שלוש שכבות קונבולוציה ושכבות Fully Connected לסיווג הסופי.
למה: נבנה במיוחד עבור משימת סיווג זו, ומסוגל ללמוד מאפיינים חזותיים מורכבים. השימוש ב-Dropout עוזר למנוע Overfitting.
Loss Function: השתמשנו ב-Categorical Crossentropy שמתאימה לסיווג.
Optimizer: Adam, מספקת שילוב טוב של מהירות והתכנסות.
תוצאות: דיוק של 0.78, עם שיפור ביכולת ההבחנה בין התמונות אך עדיין קיים קושי בהבחנה בין רחפנים ומסוקים.

VGG-16 Model

תיאור: רשת נוירונים עמוקה עם 16 שכבות, פשטות ואפקטיביות בסיווג.
למה: VGG-16 הוא מודל מוכח שמצליח לשפר את הביצועים בזיהוי אובייקטים בתמונות מורכבות.
Loss Function: Categorical Crossentropy.
Optimizer: Adam, מתאים למודלים עמוקים כמו VGG.
תוצאות: דיוק של 0.87, עם שיפור משמעותי בהבחנה בין אובייקטים.

Fine-Tuned VGG-16 Model

תיאור: מודל VGG-16 עם Fine-Tuning על הבלוק החמישי של השכבות.
למה: Fine-Tuning של השכבות העליונות מאפשר התאמה ספציפית למאפיינים של מאגר הנתונים שלנו תוך שמירה על הידע הכללי מהאימון הראשוני.
Loss Function: השתמשנו ב-Categorical Crossentropy שמתאימה לסיווג.
Optimizer: Adam, מספקת שילוב טוב של מהירות והתכנסות.
תוצאות: דיוק של 0.90, שיפור בהבדלה בין אובייקטים.

MobileNet Model

תיאור: מודל קל משקל, מתאים למערכות ניידות עם משאבים מוגבלים.
למה: MobileNet נבחר בשל יתרונותיו בביצועים גבוהים תוך שמירה על יעילות חישובית, מתאים למאגר נתונים קטן ויעיל, עם יכולת טובה לסיווג תמונות גם עם כמות מוגבלת של נתונים.
Loss Function: Categorical Crossentropy.
Optimizer: RMSprop, מציע ביצועים טובים יותר ב-MobileNet בשל הצורך ב-Learning Rate דינמי.
תוצאות: דיוק של 0.94, עם שיפור משמעותי.

Fine-Tuned MobileNet Model

תיאור: מודל MobileNet עם Fine-Tuning על 100 השכבות האחרונות.
למה: Fine-Tuning מאפשר ניצול מלא של היתרונות של MobileNet תוך התאמה לנתונים הספציפיים שלנו.
Loss Function: Categorical Crossentropy.
Optimizer: RMSprop, מציע ביצועים טובים יותר ב-MobileNet בשל הצורך ב-Learning Rate דינמי.
תוצאות: דיוק של 0.94, שמירה על ביצועים טובים.

בחירת בפרמטרים:

Batch Size: 32

תיאור: גודל ה-Batch הוא מספר הדוגמאות שהמודל מעבד לפני שהמשקלים מתעדכנים.
למה?: מאגר נתונים קטן כמו שלנו דורש Batch Size קטן יחסית כדי לאפשר למודל לעדכן את המשקלים לעתים קרובות יותר במהלך האימון. Batch Size של 32 נבחר משום שהוא מאפשר לעדכן את המשקלים בצורה תדירה, מה שמסייע בשיפור הביצועים על מאגר הנתונים הקטן.

Epochs: 20

תיאור: מספר ה-Epochs הוא מספר הסיבובים שבמהלכם המודל עובר על כל הנתונים.
למה?: כאשר מאגר הנתונים קטן יחסית (כ-1380 תמונות בסך הכל, עם כ-450 תמונות לכל קטגוריה), יש צורך באיזון בין מספיק epochs כדי לאפשר למודל ללמוד את כל המאפיינים הקיימים בנתונים, לבין הימנעות מאימון יתר-Overfitting.

Shuffle: True

תיאור: כלי חשוב המסייע בשיפור האימון של המודל על ידי הבטחת גיוון בנתונים שנראה במהלך כל Epoch. זה מאפשר למודל ללמוד בצורה יותר כללית, לשפר את היכולת שלו להכליל על נתונים חדשים, ולהקטין את הסיכוי ל-Overfitting או להטיות כלשהן הנובעות מהסדר המקורי של הדוגמאות.
למה?: השתמשנו בטכניקת mini batch.

טכניקות לשיפור המודל

Early Stopping


תיאור: טכניקת Early Stopping עוצרת את האימון כאשר הביצועים בסט הבדיקה אינם משתפרים לאחר מספר epochs.
למה?: השימוש ב-Early Stopping מונע Overfitting ומצמצם את זמן החישוב המיותר. פרמטר ה-Patience נקבע ל-5 epochs על מנת לתת למודל הזדמנות לשיפור אך להפסיק כשלא נצפה שיפור נוסף.

ReduceLRonPlateau

תיאור: הפחתת שיעור הלמידה כאשר הביצועים בסט הבדיקה אינם משתפרים לאחר מספר epochs.
למה?: הפחתת שיעור הלמידה עוזרת למודל למצוא פתרונות טובים יותר ולמנוע Convergence מוקדם מדי. הפרמטרים שנבחרו הם Factor של 0.1 ו-Patience של 3 epochs, שמטרתם לאפשר התאמה דינמית של קצב הלמידה בהתאם להתקדמות האימון.

סיכום

בהשוואת התוצאות, המודלים המתקדמים יותר כמו VGG-16 עם Fine-Tuning ו-MobileNet הציגו את הביצועים הטובים ביותר. הבחירה ב-20 Epochs ו-Batch Size של 32 תרמה להצלחה של המודלים. טכניקות כמו Early Stopping ו-ReduceLRonPlateau תרמו למניעת Overfitting ושיפור ביצועי המודלים.



עתיד

רחפנים הופכים להיות כלי משחק מרכזי בזירה הצבאית והאזרחית כאחד. היכולת לזהות ולסווג רחפנים בזמן אמת תהווה מרכיב קריטי בהגנה על תשתיות קריטיות, אירועים המוניים ואזורים רגישים.

הפרויקט שלנו יכול להתפתח בכמה כיוונים מבטיחים-

- שיפור דיוק הזיהוי: באמצעות שימוש במודלים עמוקים מתקדמים יותר, נוכל לשפר משמעותית את דיוק הזיהוי, גם בתנאי תאורה משתנים או כאשר הרחפן מוסווה.
- זיהוי איומים מתקדמים: נוכל להרחיב את היכולות של המערכת לזיהוי איומים מתקדמים יותר, כמו רחפנים הנושאים מטענים נפוצים או אמצעי איסוף מודיעין.
- אינטגרציה עם מערכות הגנה: נוכל לשלב את המערכת שלנו עם מערכות הגנה אחרות, כגון מערכות יירוט, כדי ליצור פתרון כוללני להגנה מפני איומים אוויריים.
- פיתוח ממשק משתמש אינטואיטיבי: נוכל לפתח ממשק משתמש אינטואיטיבי שיאפשר למשתמשים לקבל את המידע הרלוונטי בצורה מהירה ונוחה.

לסיכום, הפרויקט שלנו מהווה בסיס איתן לפיתוח טכנולוגיות מתקדמות להגנה על ביטחוננו. על ידי המשך פיתוח המערכת, נוכל להבטיח שהיא תישאר רלוונטית לאורך שנים רבות ותספק מענה לאיומים המתפתחים.

קישור לפרויקט - <https://colab.research.google.com/drive/1V9FA1jzURLIf7HGVTP6g-qX7O8XMTHPR?usp=sharing>

קישור למאגר הנתונים-

<https://www.google.com/url?q=https%3A%2F%2Fdrive.google.com%2Fdrive%2Ffolders%2F1fAtelTxhftYMU0UTWf7Ke0k-fpUCOhQu%3Fusp%3Dsharing>

ביבליוגרפיה - <https://www.geeksforgeeks.org/vgg-16-cnn-model>

<https://www.kaggle.com/datasets/harshwalia/bird-vs-drone-new/data>

<https://www.kaggle.com/datasets/eabdul/flying-vehicles/data>

מגישות: שילת שמעון ואביגיל חליבה לביא